

PetroAnalytics

Benchmark Petrobras vs 6 pares · intelligence financière et opérationnelle

7 empresas · 14 trimestres (2023Q1–2026Q2) · 871 fontes catalogadas · 272 fatos com fonte, data, unidade e confiança · DQS 75.5 · 147 projeções

MVC-W · SQLite · Python · painel web + GUI desktop · relatório de auditoria em PDF

- **O problema e a utilidade**
- Quem usa e como usa
- A cadeia de ponta a ponta
- Arquitetura e tecnologia (e o que foi descartado por medição)
- Resultados medidos · matriz do último trimestre
- Qualidade: DQS, evolução no tempo, fila priorizada, alerta cross-sectional
- Projeção estatística e auditoria de governança
- Descoberta do que foi anunciado · relatório de auditoria
- Limites assumidos · próximos passos

1. O problema

02

Sete empresas, sete formatos — e nenhum número comparável

- **O mesmo fato é publicado de formas incompatíveis:**
- PDF com layout a perder · planilha com três separadores · release em inglês
- Valor em dólar ou em real · trimestre rotulado de formas diferentes entre RI e SEC
- **Comparar Petrobras com seis pares exige planilha na mão — e gera erro de versão.**
- **O problema de governança:**
- Um número sem procedência não pode ir para decisão. Aqui todo fato carrega fonte, data, unidade e confiança.
- **E o que não tem confiança suficiente vai para revisão humana — nunca para o gráfico como se fosse verdade.**

7

empresas comparadas

7

formatos distintos

0

erros de carga

2. A utilidade

03

O que o sistema entrega que uma planilha não entrega



- Comparabilidade — mesmo indicador, mesma unidade, mesma moeda em toda a série.
- Descoberta — saber o que foi anunciado e ainda não está no acervo.
- Confiança — DQS por empresa×trimestre e fila priorizada do que exige análise.
- Projeção — 3 trimestres à frente, método escolhido por backtesting, com IC95.
- Governança — relatório de auditoria em PDF com as decisões do período.

Perguntas que o sistema responde sozinho:

de onde veio este número · ele é confiável · o que ainda precisa de olho humano · o próximo trimestre já saiu?

Fluxo trimestral de verdade: soltar o arquivo e rodar um comando


Passo	Comando	Quem faz	O que entrega
1. Atualizar o acervo	app_main.py etl --novos	Analista	varre o Container e processa só o que é novo
2. Conferir novidade	app_main.py descoberta	Analista	o 3T26 já foi protocolado? o número estruturado já existe?
3. Ler	app_main.py web --serve · gui	Gestor	painel de 11 abas (web) ou 8 (desktop)
4. Distribuir	app_main.py email --para ...	Analista/Gestor	e-mail com HTML + PNG + CSV anexados
5. Auditar	app_main.py auditoria relatorio	Auditor	PDF com as decisões do período

O incremental é idempotente: rodar de novo processa 0 arquivos. Carga inicial 108 arquivos em 353 s → 1 arquivo novo em 4,3 s.

4. Como funciona — a cadeia

05

Cada etapa tem uma garantia; nenhuma delas é opcional



- **Idempotência**
- reexecutar não duplica nem regrada fato (SHA-256 + prioridade de confiança);
- **Rastreabilidade**
- todo fato tem id_fonte — sem fonte ele vai para a fila de revisão, não para a matriz;
- **Projeção ≠ fato**
- projeção vive em tb_projecao, fora da matriz, sempre rotulada.

32

execuções do ETL registradas

0

erros de carga

12

tabelas no banco

Camada	Pasta	Papel	Exemplos
Model	models/	12 tabelas SQLite, De-Para, glossário, repositórios	database · repositories · depara · glossario
Worker	workers/	todo o processamento; nenhuma escrita de tela	scanner · parse_pdf · parse_tab · etl · quality_score · forecast · sec_edgar
Controller	controllers/	casos de uso finos, sem regra de negócio	Pipeline · Analytics · Source · Forecast · Mail
View	views/	web (Plotly + JS), desktop (PySide6), servidor REST	web_app · gui_app · web_server

- **Padrões:**
- MVC-W · repositório · injeção por construtor · SRP · type hints
- **Migrações idempotentes:**
- ALTER TABLE ADD COLUMN em bancos antigos, sem rebuild — por isso a base de 3 meses atrás ainda abre.

Escolha medida, não preferência

Tecnologia	Onde	Por quê
Python 3.12+	back-end	ecossistema de dados pronto para PDF e rede
SQLite	persistência	arquivo único, transacional, auditável — adequado a PoC
PyMuPDF	extração de PDF	o mais rápido no acervo (2,2 s vs 6–23 s) e acha tabelas
pdfplumber	fallback de tabela	quando o MuPDF não acha tabela válida
Plotly	Web	interativo e exporta PNG sem navegador extra
PySide6 + pyqtgraph	GUI	desktop nativo com gráficos de alta performance
reportlab + Kaleido	PDF e PNG	entregáveis sem depender de navegador
python-pptx	esta apresentação	deck gerado do banco — não pode divergir do painel
pytest	testes	regressão real: 20 bugs encontrados por teste

Destaque honesto: as bibliotecas Rust de PDF (PDFOxide, pdf-inspector) foram benchmarkadas e NÃO adotadas — são redundantes com o MuPDF (mesmas extrações) e 2,8× mais lentas.

7. Benchmark de leitura de PDF

Medido no acervo real (11 PDFs, DFs Petrobras + BP + Total)

Biblioteca	Texto	MB/s	Tabelas	Veredito
PyMuPDF 1.28	2,2 s	5,3	31	PRINCIPAL
pdf-inspector (Rust)	2,5 s	4,6	—	não adotado
PDFOxide 0.3 (Rust)	6,2 s	1,9	0 nos DFs	só fallback
pypdf 6.19	16,3 s	0,7	—	7× mais lento
pdfminer.six	22,8 s	0,5	—	10× mais lento

Conclusão medida: as libs Rust são redundantes, não melhores — as extrações caem nas mesmas chaves (rubrica, período). Trocar a biblioteca principal não ganharia um único fato e custaria velocidade e detecção de tabelas.

133

PDFs medidos

1.420

páginas lidas

2.9

páginas/seg

738

tabelas detectadas

37.9%

cobertura do acervo

Matriz 2026Q2 (USD bi) — 7 empresas, mesma unidade

Indicador	Petrobras	Shell	BP	Chevron	ExxonMobil	TotalEnergies	Equinor
Receita líquida	33,6	94,7	69,1	67,2	114,5	57,3	35,2
EBITDA ajustado	18,6	20,7	—	—	—	13,2	—
Lucro líquido	10,4	10,8	3,9	12,2	14,5	5,4	4,8
Fluxo de caixa oper.	12,2	21,4	10,9	45,3	32,3	10,9	9,5
Investimentos (CAPEX)	0,01	4,03	3,09	4,54	—	3,45	—
Dívida líquida	60,4	41,8	22,3	—	—	19,7	—


Unidade: USD bilhões, com a moeda de origem detectada por regex no nome do arquivo e conversão BRL→USD pela PTAX de fechamento do trimestre.

- **O CAPEX da Petrobras aparece como 0,01 — e está errado.**
- A comparação com os pares denunciou o defeito de extração: a aba "Investimentos" da planilha tem linhas de projeto, não o consolidado. O alerta cross-sectional isolou como P1 sem ninguém comparar tabelas à mão.

9. Estado do acervo

10

O que existe hoje, com o status de cada documento



- **Documento sem carga tem motivo gravado**
- "não achou número no documento" ≠ "perdeu para um fato já gravado com confiança maior" — o painel diz qual dos dois foi.
- **PDF narrativo não entra no ETL numérico**
- transcrição, slides, remarks e webcast são catalogados mas pulados — no acervo, 51 dos 52 pulados são narrativos.
- **Idempotência real**
- SHA-256 por arquivo; um fato existente com confiança maior nunca é rebaixado por uma extração pior.

10. Qualidade — o DQS

Cada empresa × trimestre recebe uma nota 0–100 auditável

Dimensão	Peso	Média da base
Completude	30%	40.6
Plausibilidade	25%	98.5
Consistência	15%	93.8
Rastreabilidade	15%	100.0
Tempestividade	15%	64.2
DQS médio ponderado	—	75.5

Regra de ouro:
confiança baixa vai para revisão humana, nunca para o painel como se fosse verdade.


- **Classificação**
- $\text{CONFIÁVEL} \geq 80 \cdot \text{REVISAR } 60\text{--}79 \cdot \text{NÃO CONFIÁVEL} < 60$
- Hoje: 16 CONFIÁVEL · 51 REVISAR · 0 NÃO CONFIÁVEL
- **Rastreabilidade 100,0 é real**
- todos os fatos financeiros têm id_fonte válido — e integridade referencial confere 0 órfãos.
- **DQS baixo é mapa de trabalho**
- tempestividade 64,2 diz "faltou o 2T26 de alguém" (é data de publicação); completude 40,6 diz "falta rubrica" — e aí é ação.

11. Evolução da qualidade no tempo

O scorecard guardava só o último estado — a história se perdia

DQS médio da base: 70.7 → 88.3 (+17.6) em 14 períodos

A virada em 2025Q4 coincide com a carga SEC completa daquele trimestre. Antes disso os trimestres eram SEC parciais, com completude baixa — a qualidade subiu por mais dados, não por método mais frouxo.



- Um ponto por empresa x período, gravado só quando o DQS muda de verdade:
- a série mostra evolução da qualidade, não log de execução.
- **Maior evolução: Petrobras**
- 75,4 → 99,8. Ainda em REVISAR: Equinor, 66,5 → 76,3.
- **Quem melhorou mais não é quem tem mais dado** —
- é quem tem dado completo nos dois extremos da série.

Empresa	DQS inicial	DQS atual	Variação
BP	72.5	83.4	+10.9
Chevron	72.5	89.4	+16.9
Equinor	66.5	76.3	+9.8
ExxonMobil	72.5	81.7	+9.2
Petrobras	75.4	99.8	+24.4
Shell	72.5	95.4	+22.9
TotalEnergies	69.5	92.4	+22.9

12. Fila de análise prioritizada

O que exige olho humano, em ordem de urgência

13

877	875	134	9	4
itens na fila	abertos	alertas ativos	regras de desvio	decisões registradas

- **P1 urgente · P2 revisar · P3 completar — sempre com o código do motivo.**
- **Escalonamento automático por repetição:**
 - um código de alerta que se repete mais de 3 vezes sobe um nível (P3→P2→P1). O DRIFT_ZSCORE da BP apareceu 39 vezes e foi para o topo em vez de se diluir.
- **As 9 regras, com limiar calibrável em tb_regra_alerta (sem tocar em código):**
 - DRIFT_ZSCORE · QUEBRA_ESTRUTURAL · CONTAGEM_PERIODO · REVISAO_ENTRE_EXECUCOES · ATRASO_TRIMESTRE · BAIXA_CONFIANCA · SEM_FONTE · RUBRICA_AUSENTE · OUTLIER_CROSS_SECTIONAL
- **Contrato de dados:**
 - tipos, obrigatoriedade, domínio e convenção de sinal verificados ao fim de cada execução — aponta a linha exata. 393 fatos verificados, 0 violações.

As outras 8 regras comparam com a própria história; esta compara com os pares

- **Pergunta:**
 - "esta empresa está fora da curva dos pares neste trimestre?"
- **Cálculo**
 - grupo = (trimestre, rubrica); $z = (\text{valor} - \text{média}) \div \text{desvio do grupo}$.
 - **Limiar $|z| \geq 1,8$, gravado em tb_regra_alerta (calibrável sem código).**
 - **Piso de 4 empresas por grupo**
 - sem ele, num grupo de 2 ou 3 qualquer diferença vira z alto.
 - **Só entra o que é comparável entre oil & gas**
 - receita, EBITDA, lucro, FCO, CAPEX e dívida. Efetivo fica de fora: efetivo menor é o esperado numa empresa com menos employees — não é anomalia.

Empresa	Trimestre	Métrica	Posição no grupo
CHEVRON	2026Q2	FCO 45,32	+2,0σ (7 empresas, média 20,35)
CHEVRON	2026Q1	FCO 29,85	+2,4σ (7 empresas, média 9,21)
CHEVRON	2025Q4	FCO 33,94	+2,3σ (7 empresas, média 12,35)
BP	2025Q4	Lucro -3,42	-2,1σ (6 empresas, média 1,78)
PETROBRAS	2026Q2	CAPEX 0,01	-1,9σ (5 empresas, média 3,02)
PETROBRAS	2026Q1	CAPEX 0,01	-1,9σ (6 empresas, média 3,61)

O achado que importa: CAPEX da Petrobras a 0,01 USD bi contra pares em 3,09 a 4,54. A série não caiu 98% — o valor NÃO foi extraído (a planilha tem linhas de projeto, não o consolidado). A comparação com os pares foi o que revelou.

14. Projeção estatística

O método é escolhido por medição, nunca por suposição

Dados na série	Método	Intervalo de 95%
1 ponto	repete o último valor	±15%
2 a 5 pontos	média da série	± 2 desvios-padrão
6 ou mais	backtesting entre Sazonal-Naive, Holt-Winters amortecido ($\varphi=0,85$) e Última-Observação	pela dispersão dos erros

Método escolhido	Pontos	Critério
REPETIR_15	6	1 ponto na série
MEDIA_2DP	78	2 a 5 pontos
ULTIMA_OBSERVACAO	33	backtesting
SAZONAL_NAIVE	15	backtesting
HOLT_WINTERS_DAMPED	15	backtesting

- **O intervalo alarga com o horizonte**
- ($\sqrt{h}$, pela dispersão dos erros)
- **Projeção nunca vira fato**
- vive em tb_projecao, fora da matriz, sempre rotulada.
- **Cobertura auditada**
- 49 séries · 147 pontos · 10 de 10 rubricas com fato têm projeção.

Confiança média das projeções: 0.5. Com poucos pontos o método e a confiança degradam de forma explícita — a projeção não se apresenta com a mesma segurança da série longa.

15. Governança — o que foi anunciado e ainda não está aqui

O ETL responde o que eu tenho; a descoberta responde o que falta

- **SEC EDGAR como canal confiável:**
 - submissions diz o que foi protocolado (e a reportDate define o trimestre); companyfacts traz o número estruturado por tag XBRL, com frame trimestral.
- **A lacuna de XBRL é o sinal-chave:**
 - o trimestre foi comunicado, mas o frame CY20xxQn ainda não existe — é "ainda não dá para fechar o trimestre", dito explicitamente.
- **Documento principal de 6-K é só a capa:**
 - as demonstrações estão nos anexos (Shell: 48 · Chevron: 70) e o número vem do companyfacts.
- **Exceção declarada, nunca disfarçada:**
 - Chevron e BP devolvem HTTP 403 e Petrobras/Equinor usam página dinâmica — o relatório diz isso em vez de fingir cobertura.

Empresa	CIK	Formulário
Petrobras	0001119639	6-K
Shell	0001306965	6-K
BP	0000313807	6-K
Chevron	0000093410	10-Q · 8-K
ExxonMobil	0000034088	10-Q · 8-K
TotalEnergies	0000879764	6-K
Equinor	0001140625	6-K

Fontes primárias: release e demonstrações do RI de cada empresa (136 PDFs + 27 planilhas).

Fontes secundárias: SEC XBRL, usada como conferência e preenchimento de lacuna — nunca sobrescreve o dado da RI.

16. Auditoria e relatório em PDF

17

Quem decidiu o quê, quando e com qual justificativa

- **Trilha de decisão append-only em tb_auditoria_decisao.**
- aceitar → RESOLVIDO · rejeitar · ignorar · reabrir (volta para a fila sem apagar a decisão anterior).
- **Relatório em PDF com o período escolhido**
- situação da auditoria · aging da fila · quem decidiu · a trilha do período com empresa, período e rubrica do item auditado · a fila no encerramento.
- **Gerado por três caminhos**
- CLI: `app_main.py auditoria relatorio --de ... --ate ...` · botão na aba Auditoria (web e desktop) · `GET /api/auditoria?pdf=1`



Correção do próprio sistema:
a taxa de resolução anunciava 100% com 875 itens abertos — o denominador era o número de tipos de decisão, não o total. Agora são 50% (2 de 4), e o painel mostra os dois contadores.

17. Glossário de indicadores

O que cada número significa, em que unidade e com que sinal

Código	Nome	Unidade	Sinal
RECEITA_LIQUIDA	Receita líquida	USD bi	positivo
EBITDA_AJUSTADO	EBITDA ajustado	USD bi	positivo
LUCRO_LIQUIDO	Lucro líquido (acionistas)	USD bi	positivo
FCO	Fluxo de caixa operacional	USD bi	positivo
DIVIDA_LIQUIDA	Dívida líquida	USD bi	positivo
CAPEX	Investimentos	USD bi	POSITIVO (saída de caixa)
DESPESA_OPERACIONAL	Despesas operacionais	USD bi	NEGATIVO (reduzora)
EFETIVO_TOTAL	Total de efetivo	pessoas	positivo
PRODUCAO_BOED	Produção total	kboed	positivo

- **Por que importa:**
 - sem convenção de sinal explícita, despesa positiva e CAPEX negativo invertem a leitura de qualquer gráfico.
- **Inclui fórmula e dependências**
 - de quais rubricas cada indicador derivado depende.
- **Disponível na web, no desktop e no e-mail**
 - é a leitura necessária para interpretar os gráficos, não um apêndice.

18. O que os testes encontraram

20 bugs reais — e não por leitura de código

#	Bug	Como apareceu
1	Transcrição 1T25.pdf era parseado (skip-list sem acento)	teste de classificação de PDF
2	R\$ lido como USD	teste de moeda
3	IC95 invertido em série negativa	teste de projeção
4	ZeroDivisionError na aba Qualidade com execução sem carga	suíte completa, após o modo incremental
5	Duração medida antes do parse zerava a coluna do painel	teste do painel de ETL
6	Taxa de resolução em 100% com 875 itens abertos	auditoria resumo na base real
7	GUI quebrava com base vazia (API removida no pyqtgraph 0.14)	teste da aba Projeções sem projeção
8	Lista fixa de rubricas deixava 3 indicadores sem projeção	verificação pedida pelo usuário

O mais honesto: a projeção não cobria FCL, DIVIDA_BRUTA e DESPESA_OPERACIONAL por causa de uma lista fixa no código, sem aviso na tela. Hoje é dirigida pelos dados e a aba mostra a cobertura — 10 de 10. Isso só apareceu porque alguém perguntou.

19. Limites e riscos assumidos

Assumir o limite é o que dá credibilidade

Limite	Impacto	Como está registrado
RI dinâmico (Petrobras, Equinor) ou bloqueado (Chevron, BP: 403)	sem canal primário automatizado	relatório de descoberta mostra o erro por empresa
Documento principal do 6-K é a capa	comunicado é achado, número não	anexos do index.json + companyfacts
Histórico local concentrado em 2025–2026	2023–2024 dependem da SEC	2 testes marcados como skip, explicitamente
Cobertura de rubricas desigual entre empresas	LUCRO_BRUTO só na Petrobras	DQS de completude torna visível em vez de esconder
Cobertura de 36,5% das páginas no PDF	parse lê 12 páginas (30 em DF)	"cobertura" exibida ao lado do throughput
Métrica de leitura em 133 PDFs	581 fontes sem arquivo local	ficam fora da média (não medido ≠ mediu zero)
Série curta não é tendência	projeção com intervalo largo	método e confiança degradam explicitamente
IFRS 16 não é homogeneizado	CAPEX e EBITDA divergem entre empresas	registrado como backlog

20. Próximos passos

21

Do que é manutenção para o que é/value novo

- **Ler os anexos do arquivamento SEC em profundidade**
- hoje eu entrego o arquivo, não a tabela que está dentro dele.
- **Rolling-origin**
- recalculando o passado e medir o erro real das projeções — hoje tenho método por backtesting, ainda não backtest ao longo da história viva.
- **Cenários com Brent/FX**
- e intervalo que responda à covariância dos fatores, não a uma soma de erros.
- **Método escolhido por rubrica**
- dívida é nível, não sazonalidade — a escolha não pode ser global.
- **Cache de texto por hash de PDF**
- mata o último custo do reprocessamento.
- **RI com render de JS**
- fecha o canal primário, hoje bloqueado em 2 de 7 empresas.
- **Score de proveniência**
- profundidade da cadeia: RI → SEC → derivada.

O que eu quero que levem deste projeto

"Não é o dashboard. É a cadeia de decisões:
de onde veio este número, ele é confiável, e o que ainda precisa de olho humano.

O painel mostra o resultado. O que sustenta o resultado é a procedência, a régua de qualidade e a fila de quem precisa conferir."

272	871	75.5	147	0	110
fatos	fontes catalogadas	DQS médio	projeções em 49 séries	erros de carga	testes automatizados

app_main.py web --serve · app_main.py auditoria relatorio --de ... --ate ...