

PetroAnalytics — Benchmark Petrobras vs Pares

Sistema de inteligência financeira e operacional para setor de petróleo e gás · 7 empresas · MVC-W + SQLite + Python

7	empresas	14	trimestres	871	fontes	272	fatos	75.5	DQS médio
---	----------	----	------------	-----	--------	-----	-------	------	-----------

Apresentação executiva · 12 tópicos · ~12 minutos

1. O problema

O mesmo fato é publicado por 7 empresas em formatos incompatíveis: PDF com layout, planilha com três separadores, release em inglês, valor em dólar ou em real. Comparar Petrobras com seis pares exige planilha na mão e gera erro de versão.

O problema de governança: um número sem procedência não pode ir para decisão. Aqui todo fato carrega **fonte, data, unidade e confiança** — e o que não tem confiança suficiente vai para revisão humana, não para o gráfico.

2. A utilidade

Um só número comparável entre as 7 empresas, em USD bi, com a proveniência da série inteira.

Entrega	O que resolve
Comparabilidade	mesmo indicador, mesma unidade, mesma moeda em toda a série
Descoberta	saber o que foi anunciado e ainda não está no acervo
Confiança	DQS por empresa×trimestre + fila priorizada do que exige análise
Projeção	3 trimestres à frente, método escolhido por backtesting, com IC95
Glossário	definição, fórmula e convenção de sinal de cada indicador

272	fatos financeiros	121	fatos operacionais	67	scorecards	147	projeções	877	itens em revisão
-----	----------------------	-----	-----------------------	----	------------	-----	-----------	-----	---------------------

3. Quem usa e como usa

Passo	Comando	Quem faz
Atualizar o acervo	app_main.py etl --novos (opção 3 do menu)	Analista solta o arquivo novo e roda
Conferir novidade	app_main.py descoberta	Analista pergunta se o trimestre já saiu
Ler	app_main.py web --serve · app_main.py gui	Gestor abre o painel (11 abas) ou o desktop (8 abas)
Distribuir	app_main.py email --para ...	E-mail com HTML + PNG + CSV

Fluxo trimestral de verdade: soltar o arquivo, rodar um comando, revisar a fila do que precisa de olho humano.

4. Como funciona — a cadeia

Inventário → varredura (SHA-256) → classificação do documento → parser (PyMuPDF / planilha / HTML) → De-Para PT-EN → plausibilidade → **carga com fonte e confiança** → auditoria → DQS → projeção → painel.

Garantia	Como é assegurada
Idempotência	SHA-256 por arquivo; fato existente nunca é rebaixado
Rastreabilidade	todo fato tem id_fonte; sem fonte vai para a fila de revisão
Projeção ≠ fato	projeção vive em tb_projecao, fora da matriz, sempre rotulada

26	processadas	98	sem dado	52	PDFs pulados	0	erros	32	execuções do ETL
----	-------------	----	----------	----	--------------	---	-------	----	------------------

5. Arquitetura

Camada	Pasta	Papel
Model	models/	11 tabelas SQLite, De-Para, glossário, repositórios
Worker	workers/	scan, parse_tab, parse_pdf, parse_html, SEC, qualidade, projeção, descoberta
Controller	controllers/	casos de uso finos; nenhuma regra de negócio
View	views/	Web (Plotly + JS), GUI (PySide6/pyqtgraph), servidor REST

Padrões: MVC-W, repositório, injeção por construtor, responsabilidade única e anotações de tipo.

6. Tecnologia — e por quê

Tecnologia	Onde	Por quê
Python 3.12+	back-end	ecossistema de dados pronto para PDF e rede
SQLite	persistência	arquivo único, transacional, auditável — adequado a PoC
PyMuPDF	extração de PDF	o mais rápido no acervo (2,2 s vs 6–23 s) e acha tabelas
pdfplumber	fallback de tabela	quando o MuPDF não acha tabela válida
Plotly	Web	interativo e exporta PNG sem navegador extra
PySide6 + pyqtgraph	GUI	desktop nativo com gráficos de alta performance
reportlab + Kaleido	PDF e PNG	entregáveis sem depender de navegador
pytest	testes	regressão real: 14 bugs encontrados por teste

Benchmark honesto: as bibliotecas Rust de PDF foram medidas e **não** adotadas — são redundantes com o MuPDF e 2,8× mais lentas.

7. Resultados medidos — matriz 2026Q2 (USD bi)

Indicador	PETROBRAS	SHELL	BP	CHEVRON	EXXONMOBIL	TOTALENERGIES	EQUINOR
RECEITA_LIQUIDA	33.61	94.66	69.11	67.20	114.53	57.33	35.18
EBITDA_AJUSTADO	18.61	20.71	—	—	—	13.18	—
LUCRO_LIQUIDO	10.43	10.82	3.91	12.21	14.53	5.44	4.84
FCO	12.25	21.43	10.86	45.32	32.26	10.86	9.47
DIVIDA_LIQUIDA	60.39	41.75	22.25	—	—	19.71	—

871	fontes	183	com arquivo	14	trimestres	0	erros	75.5	DQS médio
-----	--------	-----	-------------	----	------------	---	-------	------	-----------

8. Qualidade e controle

Dimensão	Peso	Nota
Completude	30%	40,6
Plausibilidade	25%	98,5
Consistência	15%	93,8
Rastreabilidade	15%	100,0
Tempestividade	15%	64,2

75.5	DQS médio	67	scorecards	134	alertas	877	fila de análise	0	erros de carga
------	-----------	----	------------	-----	---------	-----	-----------------	---	----------------

Regra de ouro: confiança baixa vai para revisão humana, nunca para o painel como se fosse verdade.

9. Projeção — método escolhido por medição

Dado na série	Método	Intervalo
1 ponto	repetir o último valor	±15%
2 a 5 pontos	média da série	±2 desvios-padrão
6 ou mais	backtesting: Sazonal-Naive, Holt-Winters amortecido, Última-Observação	IC95 pela dispersão dos erros

147	projeções	49	séries	0.5	confiança média	10	rubricas com fato	0	rubricas sem cobertura
-----	-----------	----	--------	-----	-----------------	----	-------------------	---	------------------------

10. Governança e operação

A aba Descoberta consulta a SEC e responde: o trimestre foi protocolado? o número estruturado já foi publicado?

Situação	Leitura
ANUNCIADO	documento novo do trimestre já publicado
ANUNCIADO_SEM_XBRL	comunicado existe, número estruturado ainda não
NADA_ANUNCIADO	nada publicado para o alvo ainda
lacuna de XBRL	o trimestre ainda não pode ser fechado com dado oficial

Exceções ficam visíveis: o relatório declara quando o portal de RI bloqueia automação, em vez de fingir cobertura.

11. Limites e riscos assumidos

Limite	Como tratamos
Portal de RI dinâmico ou bloqueado (403)	SEC como canal confiável; bloqueio declarado
Documento principal do 6-K é a capa	número vem do XBRL (companyfacts)
Divergência de rubrica entre RIs	De-Para aprendido + revisão humana
Cobertura desigual por rubrica	DQS de completude torna isso visível
Série curta	método e confiança degradam explicitamente

12. Próximos passos

1. Ler os **anexos** do arquivamento SEC, não só o documento principal.
2. Escolher o método de projeção **por rubrica** (dívida é nível, não sazonalidade).
3. **Rolling-origin**: recalcular o passado e medir o erro real das projeções.
4. Cenários com Brent/FX e intervalo que responda à covariância dos fatores.
5. RI com render de JS para fechar o canal primário bloqueado.

Pergunta que o sistema responde sozinho: **de onde veio este número, ele é confiável e o que ainda precisa de olho humano?**